

面向生物医学文献的多策略多标签分类与主动学习研究

李哲夫 2023011400 生 32

<https://github.com/zf-li23/pubmed-spatial-tracker>

一、选题背景与意义

生物医学文献正以指数速度增长：以空间转录组学为例，PubMed 年发文量从 2010 年不足 20 篇激增至 2025 年 2,638 篇。自动文献分类面临三重挑战：(1) 文本稀疏，词袋模型无法捕捉医学术语语义关联；(2) 标签空间复杂，一篇文献同时涉及研究类别、生物领域、技术平台和分析方法，构成多标签问题；(3) 标注成本极高，大规模标注不现实。

本课题在两个数据集上系统比较多策略机器学习方法：(1) 自建的 PubMed Spatial Tracker¹ 空间转录组学文献库（7,029 篇，含领域精细化标签体系）；(2) OHSUMED² 基准数据集（348,566 篇，MeSH 多标签标注）。两个数据集覆盖类别多分类、多标签预测与主动学习三个核心问题，支撑贝叶斯学习、集成学习、深度学习、无监督学习、生成式模型、基于实例的学习等全部课程模块的主流算法系统比较。

我是生命学院生物信息学方向的学生，本项目最初受课程作业一启发，为服务于我日常科研中的文献阅读需求而建立，不属于任何课程或 SRT 项目。

二、拟采用的特征与算法

2.1 文本表示（4 种）

- **TF-IDF**：1-2 gram, max_features=5,000, 稀疏表示基线。
- **BioBERT**：dmis-lab/biobert-base-cased-v1.1 对标题 + 摘要 + MeSH 拼接文本做 mean pooling（768 维）。
- **LDA**：全库文本做 Latent Dirichlet Allocation ($K = 15$)，每篇文献表示为主题分布向量。
- **元特征**：出版年份、期刊类型、MeSH 存在标志，拼接至上述向量末端。

2.2 分类算法（12 种）

所有算法在两个数据集上独立评估，覆盖课程全部主要模块：

课程模块	算法	适用子任务
贝叶斯学习	Naïve Bayes	类别分类、丢弃判别
基于实例的学习	k-NN、SVM(RBF)	类别分类
回归学习	Logistic Regression	类别分类、丢弃判别
集成学习 (Bagging)	Random Forest	类别、标签、丢弃判别
集成学习 (Boosting)	AdaBoost, XGBoost, LightGBM	类别、标签、丢弃判别
深度学习	BioBERT+MLP 微调	类别分类
无监督学习	LDA 主题 + 聚类可视化	文献子领域发现
生成式模型	GPT-4o Zero-shot	类别分类（直接推断 + 思维链）

总计 12 种独立算法覆盖全部课程模块；多标签额外实现三种问题转换策略。

2.3 主动学习（3 种策略）

- **不确定性采样**：基于 SVM margin $1 - |P_{\max} - P_{\text{second}}|$ ，选最不确定样本。
- **熵采样**：基于预测概率分布的香农熵 $-\sum_i P_i \log P_i$ 。

¹代码仓库：<https://github.com/zf-li23/pubmed-spatial-tracker>，含 PubMed 检索、规则引擎、Web 标注界面、ML 管线及主动学习流程。

²<https://trec.nist.gov/data/filtering/t9.filtering.tar.gz>

- **委员会查询**：多分类器投票分歧度（RF、SVM、XGBoost 预测不一致的样本优先）。

迭代流程：初始 50 篇 → 选 20 篇 → 重训 → 循环 10 轮。随机采样作为基线。

此外，针对空间转录组学文献的每类别合法标签空间约束策略（如 Review 仅 1 个 domain 标签、Technology 最多 2 个技术标签），通过消融实验量化领域知识收益；OHSUMED 以 MeSH 层级约束作为类比。

三、数据与实验方案

3.1 数据集

属性	Spatial Tracker	OHSUMED
来源	PubMed 检索（14 种技术平台 + 通用词）	MEDLINE 1987–1991 子集
规模	7,029 篇（481 篇已标注）	348,566 篇（全部含 MeSH 标注）
标签类型	5 类别 + 45 个语义标签	多标签 MeSH 词表（数万标签）
任务	类别分类 + 多标签 + 丢弃判别	多标签 MeSH 分类
特点	领域精细标注、主动学习闭环	大规模、基准化、可复现

两个数据集互补：Spatial Tracker 验证领域精细化标注与主动学习的协同效应，OHSUMED 提供大规模标准基准确保方法可复现性和统计显著性。

3.2 实验设计

实验	目的	方法
1: 特征对比	最优文本表示	固定 SVM, TF-IDF/BioBERT/LDA/组合特征, 双数据集 5 折 CV
2: 算法全矩阵	12 种算法排序	固定 BioBERT, 12 算法比 Macro F1 与训练时间（双数据集）
3: 多标签策略	最优转换策略	BR/CC/LP × 基分类器, 比 Jaccard 与训练时间
4: 约束消融	领域知识收益	无约束 vs 标签空间约束/MeSH 层级约束的 F1 差异
5: 主动学习	查询策略对比	不确定性/熵/委员会 × 10 轮, 学习曲线
6: 学习曲线	标注饱和度	训练集 50→400 各类别 F1 收敛, 双数据集对比
7: 跨数据迁移	泛化验证	Tracker→OHSUMED 及反向迁移 F1 差异

四、评价方案与预期结果

4.1 评价指标

类别分类：Accuracy, Macro/Weighted F1, Cohen’s κ ；多标签：Jaccard, Hamming Loss；主动学习：达 85% F1 标注量、学习曲线 AUC；跨数据集：迁移 F1 差异。

4.2 预期结果

(1) **算法排序**: BioBERT+MLP > XGBoost > LightGBM > RF > SVM > AdaBoost > LR > k -NN > NB。GPT-4o 零样本在常见类别准确率高、罕见类别急剧下降，暴露 LLM 尾部知识盲区。

(2) **约束策略**在 Spatial Tracker 上提升标签 F1 8–12%（纠正跨组误报），OHSUMED 上利用 MeSH 层级提升 3–5%。

(3) **主动学习委员会** > 熵 > 不确定性 > 随机基线，节省 40–60% 标注量。OHSUMED 大规模验证排除小样本偶然性。

(4) **迁移学习**双数据集共享 PubMed 格式，预期迁移 F1 损失 <15%。