

# 面向生物医学文献的多策略多标签分类方法系统比较研究——以空间转录组学文献为例

李哲夫 2023011400 生 32

<https://github.com/zf-li23/pubmed-spatial-tracker>

## 一、选题背景与意义

生物医学文献正以指数速度增长——空间转录组学领域 PubMed 年发文量从 2020 年之前不足 500 篇激增至 2025 年 4,150 篇。自动文献分类面临三重挑战：(1) 文本稀疏，词袋模型无法捕捉医学术语语义关联；(2) 标签空间复杂，一篇文献同时涉及研究类别、生物领域、技术平台和分析方法，构成多标签问题；(3) 标注成本极高，大规模人工标注不现实。

本课题在四个独立数据集上系统比较多策略机器学习方法：(1) OHSUMED<sup>1</sup> (~294K 篇, 14,466 个 MeSH 词)，(2) PubMed-MultiLabel<sup>2</sup> (10K 篇, 15 个 MeSH 顶级类别)，(3) PGB<sup>3</sup> (~30M 篇, 含 MeSH 层级 + 引用图)，(4) 自建空间转录组学文献库 (约数千篇, 待通过 PubMed 检索构建)。四个数据集从标签粒度 (15→14,466 类)、信息维度 (纯文本 → 异构图) 和标注完备性 (全标注 → 待标注) 形成天然梯度，支撑贝叶斯学习、集成学习、深度学习、无监督学习、基于实例的学习、图表示学习等模块的算法系统比较。

本次为修订重提交。相比初版，我深入研究了生物医学文献分类领域，理解了 MeSH 主题词层级体系，重构了项目架构，新增两个高质量全标注基准数据集，并找到利用 DeepSeek API (OpenAI 兼容格式, deepseek-v4 模型) 进行批量标注<sup>4</sup>的方法来解决目标数据集标注问题。算法方面，受 PGB 启发新增了图表示学习方法 (node2vec、GCN、GraphSAGE)。为严格遵守课程 AI 使用规定，我已删除仓库全部 AI 生成代码，将从头手写并全程使用 Git 记录。本项目不属于任何课程或 SRT 项目。

## 二、拟采用的特征与算法

### 2.1 文本表示

采用 4 种互补的文本表示方法，从不同粒度捕捉文献语义：

- **TF-IDF** (1-2 gram, max\_features=5,000)：词级稀疏特征，可解释性强，作为经典基线。
- **BioBERT** (dmis-lab/biobert-base-cased-v1.1, mean pooling 至 768 维)：预训练语言模型，捕捉医学术语的上下文语义关系。
- **LDA** (Latent Dirichlet Allocation,  $K = 15$ )：文档级主题分布，捕捉隐式的主题结构。
- **元特征** (出版年份、期刊类型、MeSH 存在标志等)：非文本信号，辅助分类决策。

多种表示对比可揭示语义深度 (TF-IDF→BioBERT)、结构粒度 (词级 → 文档级) 和信息类型 (文本 → 非文本) 对分类性能的贡献。

### 2.2 分类算法 (12 种)

| 课程模块            | 算法                       | 适用于任务    |
|-----------------|--------------------------|----------|
| 贝叶斯学习           | Naïve Bayes              | 类别分类     |
| 基于实例的学习         | k-NN, SVM(RBF)           | 类别分类     |
| 回归学习            | Logistic Regression      | 类别分类     |
| 集成学习 (Bagging)  | Random Forest            | 类别、标签分类  |
| 集成学习 (Boosting) | AdaBoost, XGBoost        | 类别、标签分类  |
| 深度学习            | BioBERT+MLP 微调           | 类别分类     |
| 无监督学习           | LDA 主题 + 聚类              | 文献子领域发现  |
| 图表示学习           | node2vec, GCN, GraphSAGE | PGB 节点分类 |

共 12 种算法，覆盖课程全部主要模块。图方法仅适用于 PGB (天然图结构)，其余方法在三个全标注数据集上独立评估。多标签任务额外对比 Binary Relevance (BR, 每个标签独立二

<sup>1</sup><https://trec.nist.gov/data/filtering/t9.filtering.tar.gz>

<sup>2</sup><https://www.kaggle.com/datasets/owaishan9654/pubmed-multilabel-text-classification>

<sup>3</sup>Lee & Ho, arXiv:2305.02691, 2023

<sup>4</sup>Touchent et al., arXiv:2506.20331, 2025

分类)、Classifier Chains (CC, 链式传递标签依赖) 和 Label Powerset (LP, 将标签组合转为多分类) 三种问题转换策略。

三、数据与实验方案

3.1 数据集

| 属性   | OHSUMED         | PubMed-ML | PGB          | Spatial Tracker  |
|------|-----------------|-----------|--------------|------------------|
| 来源   | MEDLINE 1987-91 | Kaggle    | S2ORC+PubMed | PubMed 检索 (待构建)  |
| 规模   | ~294K 篇         | 10K 篇     | ~30M 篇       | ~ 数千篇 (待标注)      |
| 标签空间 | 14,466 MeSH 词   | 15 粗分类    | 3 类 +MeSH 层级 | 5 类 + 若干标签 (待设计) |
| 主要任务 | 多标签分类           | 多标签分类     | 节点分类         | 类别 + 多标签 + 丢弃    |
| 标注状态 | 全量标注            | 全量标注      | 全量标注         | LLM 批量标注 (待进行)   |

3.2 渐进式实验设计

实验按三步渐进组织，每一步以上一步结果为输入：

Step 1（多数据集算法筛选）——在三个全标注数据集上全面对比 12 种算法和 4 种文本表示：

- 固定 SVM，对比 TF-IDF/BioBERT/LDA/组合的 5 折 CV Macro F1，选出**最优文本表示**。
- 固定 BioBERT 嵌入，对比 12 种算法的 Macro F1 与训练时间，在 OHSUMED（14K 稀疏标签）和 PubMed-ML（15 稠密标签）上分别考察**标签密度**对算法排序的影响。
- 在 PGB 上，额外引入**图嵌入 + 图神经网络**，对比纯文本 vs 文本 + 图结构 vs 文本 + 图 + MeSH 层级三档性能，量化结构信息的边际收益。

Step 2（目标数据集构建与应用）——构建空间转录组学文献数据集并验证最佳方法：

- 设计 PubMed 检索式，爬取空间转录组学相关文献，构建带标题 + 摘要 + MeSH 词的原始库。
- 参考 Biomed-Enriched 两阶段方法：DeepSeek API 标注 → 蒸馏模型扩标全量 → 以手动标注子集评估质量。
- 将 Step 1 选出的 top-3 方法应用于该数据集，对比 **BioBERT+MLP 基线**与最优替代方法的性能差异。

Step 3（迁移微调探索）——探索**宽泛** → **精细**的迁移学习范式：

- 对支持增量学习的算法（BioBERT+MLP、XGBoost warm start、GCN/GraphSAGE），在 OHSUMED 或 PGB 上预训练，在空间转录组学数据上微调，对比微调前后的 F1 增量。

四、评价方案与预期结果

4.1 评价指标

类别分类：Accuracy、Macro/Weighted F1、Cohen’s  $\kappa$ ；多标签：Jaccard、Hamming Loss、Per-label F1；图节点分类：Micro/Macro F1；迁移学习：微调前后 F1 增量。

4.2 预期结果

(1) **算法排序**: BioBERT+MLP ≥ XGBoost ≥ RF ≥ SVM ≥ AdaBoost ≥ LR ≥  $k$ -NN ≥ NB (OHSUMED 上集成方法优势更显著，PubMed-ML 上差距缩小)。

(2) **图结构价值**: PGB 上引入 MeSH 层级信息和图结构的 GCN/GraphSAGE 相比纯文本方法预期有一定提升，验证结构信息对文献分类的补充价值。

(3) **LLM 标注可行性**: DeepSeek 标注与人工标注在常见类别上预期有较高一致率，蒸馏后下游 F1 可接近人工标注水平。

(4) **迁移微调增益**: 在宽泛生物学数据上预训练后，于空间转录组学数据上微调预期能进一步提升 F1，验证”宽泛预训练 + 领域微调”范式的有效性。