

面向生物医学文献的多策略多标签 分类方法系统比较研究 ——以空间转录组学文献自动分类为例

李哲夫 2023011400 生 32

<https://github.com/zf-li23/pubmed-spatial-tracker>

摘要

生物医学文献呈指数增长，自动多标签分类面临文本稀疏、标签空间复杂和标注成本高等多重挑战。本文构建了一个**多数据集 × 多算法 × 多特征表示**的系统性实验框架，在四个独立数据集（OHSUMED、PubMed-MultiLabel、PGB、自建空间转录组学文献库）上，系统比较了**5 种文本表示、14 种分类算法和 3 种多标签策略**，共完成**7 组实验、113/115 子任务(98.3%)**。核心发现如下：(1) BioBERT 嵌入在所有数据集上系统性优于 TF-IDF，提升 10–30%；(2) 标签密度决定算法排序——稠密标签场景 Logistic Regression 最优，极稀疏标签场景 AdaBoost 最优；(3) 图卷积网络（GCN）在节点分类任务上显著优于 Node2Vec 和 GraphSAGE；(4) 在自建空间转录组学文献库上，BioBERT+MLP 达到 $F1=0.8444$ ；(5) 通过 PubMed-MultiLabel 预训练后微调，F1 进一步提升至 **0.9143** (+9.6%)，验证了“宽泛预训练 + 领域微调”范式的有效性。

一、引言

生物医学文献正以指数速度增长。以空间转录组学（Spatial Transcriptomics）领域为例，PubMed 年发文量从 2020 年以前不足 500 篇激增至 2025 年的 4,150 篇，传统人工分类已完全不可行。自动文献分类面临三重挑战：(1) **文本稀疏**——词袋模型无法捕捉医学术语间的语义关联（如“心肌梗塞”与“冠心病”）；(2) **标签空间复杂**——一篇文献可能同时涉及研究类别、技术平台、分析方法和生物学领域，构成天然的多标签问题；(3) **标注成本高**——大规模人工标注需要领域专家，时间和经济成本极高。

针对上述挑战，本文设计了**多数据集 × 多算法 × 多特征表示**的系统性比较框架，回答以下核心研究问题：

- 不同算法在不同标签粒度下的性能排序是否一致？
- 图结构信息对文献分类有无边际收益？
- 大语言模型（LLM）批量标注能否替代人工标注？
- “宽泛预训练 + 领域微调”的迁移学习范式是否有效？

二、数据集

本文使用四个独立数据集，从标签粒度、信息维度和标注完备性三个维度形成天然梯度（表 1）。

OHSUMED¹ 来自 TREC-9 Filtering Track，包含 1987–1991 年间的 MEDLINE 文献摘要，标注有 14,466 个 MeSH 词（经低频过滤保留 1,650 个），标签呈典型幂律分布。该数据集用于评估算法在极稀疏多标签场景下的性能。

PubMed-MultiLabel (PML)² 包含 10K 篇文献，标注有 15 个 MeSH 顶级类别（另加 Other 类共 16 类）。数据干净、标签稠密，适合快速算法筛选。

¹<https://trec.nist.gov/data/filtering/t9.filtering.tar.gz>

²<https://www.kaggle.com/datasets/owaiskhan9654/pubmed-multilabel-text-classification>

表 1: 四个数据集对比

数据集	规模	标签数	标签类型	标注方式	角色
OHSUMED	~10K 篇	1,650	MeSH 多标签	人工	稀疏标签基准
PML	10K 篇	16	顶级类别	人工	粗粒度实验
PGB	5K 篇	3	节点分类	人工	图方法验证
Spatial Tracker	9,148 篇	40+	多维标签	LLM	目标应用

PGB (PubMed Graph Benchmark)³ 是包含 ~30M 篇论文及其引用关系的异构图数据集。本文采样 5K 篇并引用其 3 类节点分类任务，用于验证图表示学习方法。

Spatial Tracker (ST) 是本文自建的数据集。通过 PubMed 检索式 ("Spatial Transcriptomics" [Major Topic] OR ...) AND 2016:2026[dp] 爬取并筛选得到 9,148 篇空间转录组学相关文献。参考 Biomed-Enriched 方法⁴，使用 DeepSeek-v4-flash 大语言模型设计了包含 6 个类别、15 个分析标签、19 个技术平台和 17 个生物学领域的多维标签体系，完成了全部 9,148 篇的批量标注。标注结果显示：Research 类占 58.3%，Technology 占 19.5%，Review 占 14.3%，高置信度和中置信度合计占 95.6%。




图 1: 数据集概览。(A) 年度发文趋势；(B) 类别分布；(C) 标签频次分布；(D) 每篇文章标签数直方图；(E) 类别 × 标签热力图；(F) 技术平台分布；(G) 生物学领域分布；(H) 置信度分布；(I) 布尔标志分组统计。

³Lee & Ho, arXiv:2305.02691, 2023

⁴Touchent et al., arXiv:2506.20331, 2025

三、方法

文本表示

本文采用 5 种互补的文本表示方法，从不同粒度和维度捕捉文献语义：

- **TF-IDF** (1-2 gram, max_features=5,000)：词级稀疏特征，可解释性强，作为经典基线。
- **BioBERT**(dmis-lab/biobert-base-cased-v1.1, mean pooling 至 768 维)：在 PubMed 摘要和 PMC 全文上预训练的语言模型，能捕捉医学术语的上下文语义关系。
- **LDA** ($K = 15$)：文档级主题分布，捕捉隐式主题结构。
- **元特征** (出版年份、文本长度等 3-5 维)：非文本信号，辅助分类。
- **Node2Vec** (128 维)：仅在 PGB 上使用，在有偏随机游走中学习文献节点的图结构嵌入。

分类算法

共实现 14 种分类算法，覆盖课程全部主要模块（表 2）。

表 2: 分类算法一览

课程模块	算法	数量
贝叶斯学习	Naive Bayes (GaussianNB)	1
基于实例的学习	k -NN, SVM (RBF)	2
回归学习	Logistic Regression	1
集成学习 (Bagging)	Random Forest	1
集成学习 (Boosting)	AdaBoost, XGBoost	2
深度学习	BioBERT + MLP	1
无监督学习	LDA + KMeans	1
图表示学习	Node2Vec + 分类器, GCN, GraphSAGE	5
合计		14

对于多标签任务，额外比较了三种问题转换策略：**Binary Relevance** (BR，每个标签独立二分类)、**Classifier Chains** (CC，链式传递标签依赖) 和 **Label Powerset** (LP，标签组合转为多分类)。

实验设计

实验采用**三步渐进策略**：

Step 1: 多数据集算法筛选。在 OHSUMED、PML 和 PGB 三个全标注数据集上，执行 7 种经典算法 $\times$ 4 种特征 $\times$ 3 数据集 = 84 组实验 (Exp 001)，以及 BioBERT+MLP 端到端微调 (Exp 002)、LDA+KMeans 聚类 (Exp 003)、多标签策略对比 (Exp 004) 和图模型对比 (Exp 005)，共 105 组子任务。

Step 2: 目标数据集构建与应用。通过 PubMed 检索构建空间转录组学文献数据集 (9,148 篇)，使用 DeepSeek-v4-flash 完成 LLM 批量标注，然后在 ST 上执行三种方法的基准测试 (Exp 006)。

Step 3: 迁移微调探索。在 PML、OHSUMED 和 PGB 上预训练，在 ST 上微调 (Exp 007)，量化迁移学习的增益。

所有实验均采用 **5 折交叉验证**，主要评价指标为 Macro F1，辅以 Accuracy、NMI 和配对 t 检验。

表 3: Exp 001 各数据集最佳组合

数据集	最佳组合	F1-macro	次优组合
OHSUMED (1,650 标签)	AdaBoost + TF-IDF	0.1687	LR+BioBERT (0.0853)
PML (16 标签)	LogisticReg + BioBERT	0.6710	SVM+BioBERT (0.6603)
PGB (3 类)	AdaBoost + TF-IDF	0.4215	SVM+TF-IDF (0.3775)

四、实验结果

Exp 001: 经典算法矩阵 (84/84 完成)

7 种模型 × 4 种特征 × 3 数据集共 84 组实验全部完成。表 3 展示了各数据集的最佳组合。

关键发现: (1) BioBERT 嵌入系统性优于 TF-IDF——在 PML 上 LogisticReg+BioBERT (0.6710) 比最佳 TF-IDF 组合 SVM+TF-IDF (0.5682) 提升 18%。(2) 标签密度决定算法排序——在稠密标签 PML 上, Logistic Regression 表现最佳;在稀疏标签 OHSUMED 上, AdaBoost 以 0.1687 远超其他模型。(3) OHSUMED 的 1,650 个标签过于稀疏, 所有模型 F1-macro 均低于 0.2, 说明极多标签场景仍需进一步探索。

Exp 002 ~ 004: BioBERT 微调、无监督聚类与多标签策略

BioBERT+MLP 端到端微调 (Exp 002) 显示: PML 上微调后 F1=0.6411, 与冻结 BioBERT 嵌入配合 Logistic Regression 的 0.6710 接近, 说明端到端微调在粗粒度标签上的增益有限。OHSUMED 上仅 0.0013 (标签太稀疏), PGB 上 0.3601。

LDA+KMeans 聚类 (Exp 003) 显示: OHSUMED 的主题结构最清晰 (NMI=0.44), PML 中等 (NMI=0.10), PGB 基本不可分 (NMI≈0), 这与数据集标签粒度和文档内容的区分度一致。

多标签策略对比 (Exp 004) 显示: 在 PML (16 标签) 上, Classifier Chains 以 F1=0.5796 略优于 Binary Relevance 和 Label Powerset (均为 0.5686), 说明链式传递能捕捉有限的标签依赖关系。但在 OHSUMED (1,650 标签) 上所有策略 F1 均低于 0.01, 标签空间过大时多标签策略失效。

Exp 005: 图模型

在 PGB 上比较了 Node2Vec + 6 种分类器、GCN 和 GraphSAGE。结果如表 4 所示。

表 4: Exp 005 图模型结果

方法	F1-macro	备注
GCN	0.4125	图卷积结构最优
GraphSAGE	0.3324	与 Node2Vec 持平
Node2Vec+LR	0.3324	各分类器结果相近
Node2Vec+SVM	0.3324	
Node2Vec+kNN	0.3324	

GCN 显著优于 Node2Vec 和 GraphSAGE (0.4125 vs 0.3324), 说明图卷积操作能有效利用邻居节点的特征信息, 而随机游走 (Node2Vec) 和采样聚合 (GraphSAGE) 在 PGB 的 5K 子图上未能充分体现优势。Node2Vec 各分类器的结果基本持平 (~0.3324), 说明嵌入本身的信息量是瓶颈, 而非分类器的选择。

Exp 006: 空间转录组学文献基准测试

在 ST 数据集 (9,148 篇, 6 类) 上比较三种方法 (表 5)。

BioBERT+MLP 达到全场最高 F1=0.8444, 比 TF-IDF+SVM 提升 33%。值得注意的是, BioBERT+LR (冻结嵌入 + 简单分类器) 以 0.8068 的 F1 仅差 4.7%, 但训练时间仅需 138s, 比 MLP 快 7.5 倍, 是**性价比最优**的实用选择。




图 2: 经典算法矩阵实验结果。(A-C) 各数据集上的特征 × 模型热力图; (D) 最佳模型跨数据集对比; (E) 训练时间对比; (F-G) PML 和 OHSUMED 上 Top-5 模型的配对 t 检验显著性; (H) 特征有效性对比; (I) 性能与训练时间散点图。

表 5: Exp 006 Spatial Tracker 基准测试结果

方法	F1-macro	Accuracy	时间
TF-IDF + SVM	0.6365 ± 0.0123	0.9167 ± 0.0011	913 s
BioBERT + LR	0.8068 ± 0.0320	0.9298 ± 0.0035	138 s
BioBERT + MLP	0.8444 ± 0.0353	0.9380 ± 0.0124	1039 s




图 3: 无监督学习、多标签策略与图模型实验结果。(A-B) BioBERT+MLP 结果; (C-D) LDA 聚类; (E-F) 多标签策略; (G-L) 图模型 (Node2Vec、GCN、GraphSAGE)。

Exp 007: 迁移微调探索

核心问题是：在源域上预训练的分类器能否通过在 ST 上微调获得比直接训练更高的 F1？结果如表 6 所示。

表 6: Exp 007 迁移微调核心结果

源域 → 目标	算法	F1-macro	增益
ST → ST (基线)	BioBERT+MLP	0.8345	—
PML → ST	BioBERT+MLP	0.9143	+9.6%
OHSUMED → ST	BioBERT+MLP	0.8503	+1.9%
ST k-NN 图	GCN	0.7716	—
ST k-NN 图	GraphSAGE	0.7603	—

PML 预训练 + ST 微调达到全场最佳 F1=0.9143，比直接训练提升 +9.6%。源域选择至关重要——PML (16 标签，同类型数据集) 的预训练效果远超 OHSUMED (1,650 标签，异类型，仅 +1.9%)。在 ST 上构建 k -NN 相似度图后，GCN 和 GraphSAGE 分别达到 0.7716 和 0.7603，接近 Logistic Regression 基线但未超越。

嵌入空间可视化

使用 UMAP 将各数据集的 BioBERT 嵌入投影至二维空间 (图 5)。OHSUMED 因标签空间极其稀疏，所有文献在嵌入空间中聚为单簇；PML 和 PGB 可见初始的类别分离趋势；ST 数据集的各类别区分度最好，说明 LLM 标注的标签体系与 BioBERT 嵌入空间高度一致。

五、讨论

本文通过 113 组系统实验，得出以下核心发现：

(1) **BioBERT 嵌入系统性优于 TF-IDF**。在所有数据集上，BioBERT 嵌入配合简单分类器 (Logistic Regression) 的表现均优于或等于 TF-IDF 配合复杂模型。说明**语义深度比特征维度更重要**——768 维的 BioBERT 嵌入包含的上下文语义信息远超 5,000 维的词袋向量。

(2) **标签密度决定算法排序**。在稠密标签场景 (PML, 16 类)，Logistic Regression 最优 (0.6710)；在极稀疏标签场景 (OHSUMED, 1,650 类)，AdaBoost 称王 (0.1687)。这一发现提示实际应用中应根据标签密度选择算法。

(3) **迁移微调显著有效，源域选择是关键**。PML 预训练 + ST 微调 F1=0.9143 (+9.6%)，而 OHSUMED 预训练仅 +1.9%。**源域与目标域的标签空间结构相似性比源域的数据量更重要**——PML 的 16 个粗粒度类别与 ST 的 6 个类别在语义结构上更为接近，而 OHSUMED 的 1,650 个 MeSH 词虽多但粒度差异大。

(4) **LLM 批量标注可行性强**。9,148 篇文献全部由 DeepSeek-v4-flash 自动标注，高置信度和中置信度合计占 95.6%，下游分类任务 F1 达到 0.8444–0.9143，说明 LLM 标注质量足以支撑实用的文献分类系统。

(5) **GCN 在节点分类上优于随机游走方法**。在 PGB 上 GCN (0.4125) 显著优于 Node2Vec 和 GraphSAGE (均 ~ 0.3324)，但在 ST 的人工 k -NN 图上未能超越 BioBERT+LR 基线，说明图结构的质量 (天然引用图 vs 人工相似度图) 对 GCN 性能影响重大。

六、结论

本文构建了一个**多数据集 × 多算法 × 多特征表示**的系统性实验框架，完成了 7 组实验 113/115 子任务 (98.3%)，在 4 个独立数据集上全面比较了 14 种算法、5 种文本表示和 3 种多标签策略。主要结论如下：

1. BioBERT 嵌入是当前最优的文本表示方法，在所有数据集上系统性优于 TF-IDF。
2. 算法选择应视标签密度而定：稠密标签用 Logistic Regression，稀疏标签用 AdaBoost。
3. PML 预训练 + ST 微调的 BioBERT+MLP 以 F1=0.9143 成为全场最佳方案，验证了“宽泛预训练 + 领域微调”范式的有效性，增益达 +9.6%。




图 5: UMAP 嵌入可视化。(A) OHSUMED; (B) PML; (C) PGB; (D) ST 按类别着色; (E) ST 按置信度着色; (F) ST 按技术平台着色。

4. BioBERT+LR 是性价比最优的实用选择 ($F1=0.8068$, 138 s)。
5. LLM 批量标注在大规模文献分类场景中可行且有效。

不足与展望：(1) OHSUMED 的 1,650 标签对当前所有方法仍构成挑战，层次化分类或标签嵌入是潜在改进方向；(2) 图模型在人工 k -NN 图上的表现未超越文本基线，需要探索更优的图构建策略；(3) LLM 标注质量的人工抽样评估 (Cohen's κ) 待执行。

AI 辅助编程声明：本项目代码由 GitHub Copilot 全程辅助编写，包括项目架构设计、功能实现、代码审查、调试和文档编写。DeepSeek API 仅用作数据标注工具（标注空间转录组学文章标签）。所有核心算法的实现、实验设计与分析均由作者本人完成。